

ANALISI PREDITTIVA SUL DATASET OULAD

Lavinia Rotellini

OVERVIEW

1 Presentazione
2 Introduzione
3 Realizzazione di un dataset in ambito EDM
4 Specificità del Pre-processing
5 Il dataset OULAD
6 Introduzione seconda parte
7 Analisi delle variabili
8 Clustering
9 Feature Importance e Conclusioni

INTRODUZIONE

La prima parte del lavoro presenta una breve **ricognizione sul TEL**, oltre a specificare le **metodologie di lavoro** con dataset EDM e le **risorse principali** in questo ambito.

La task proposta nella seconda parte dello studio è un'**analisi predittiva** di **classificazione con feature importance** per comprendere gli aspetti più significativi che determinano l'andamento della carriera di uno studente.

Lo studio presentato oggi si situa nell'ambito del **technology-enhanced learning**, campo di studi nato negli anni '90.

Il TEL si articola in **tre ambiti**:

- educational data mining
- learning analytics
- academic analysis



In particolare, il presente lavoro si situa nell'ambito **dell'educational data mining**: lo studio di dati di tipo educativo allo scopo di scoprire schemi e realizzare predizioni sui comportamenti degli studenti.

REALIZZAZIONE DI UN EDM DATASET


Task con molti fattori di complessità per la quale possiamo avere cinque diverse applicazioni:



Evaluations



Scientific Inquiry




Decision Support Systems

Ma anche:

- Student Modeling
- Adaptive Systems

I dati sono reperibili da fonti diverse:



Face-to-face learning



Virtual Learning Environments




Massive Online Open Courses



Learning Management Systems

SPECIFICITA' DEL PREPROCESSING


I dati nell'educational data mining presentano alcune peculiarità che implicano trattamenti specifici.



I DATASET PER L'EDM



DataShop @CMU

The logo for Mendeley Data, featuring a red stylized "M" icon followed by the text "MENDELEY DATA" in red and grey.

OLAD DATASET

È stato scelto per tre ragioni:

- Affermato in letteratura
- Varietà di informazioni
- Accessibilità

Caratteristiche principali:

- Student-oriented
- Organizzazione per moduli
- Tre tipi di dato

SECONDA PARTE:

ANALISI PREDITTIVA

E


FEATURE IMPORTANCE

ANALISI DELLE VARIABILI

- Le tabelle sono state unite con un **inner join**
- Aggregate sulla base di **id_student**
- Specifiche di data transformation: **NaN** e **granularità** delle features
- Analisi della correlazione rispetto a **score**

Analisi distribuzionale di **final_result**

- **Gender**
- **imd_band**
- **Disability**




CLUSTERING

È stato effettuato il clustering dei dati con visualizzazione tramite PCA e k = 4

I cluster identificati presentavano le seguenti caratteristiche:

- 0: F, very_low, iscrizione fortemente tardiva, late_submission
- 1: M, very_low, iscrizione_fortemente_anticipata, submission_on_time
- 2: F, very_low, iscrizione_fortemente_anticipata, submission_on_time
- 3: M, very_high, iscrizione fortemente tardiva, submission_on_time



FEATURE IMPORTANCE E CONCLUSIONI

L'analisi condotta ha permesso di identificare un insieme coerente di variabili predittive associate all'andamento della carriera di uno studente. Le feature più rilevanti individuate sono le seguenti:

- **Indicatori di engagement:** `total_clicks`, `submission`
- **Performance intermedie:** `assessment_type`, `weight`
- **Difficoltà inherente ai corsi:** `module_presentation_length`

Tali conoscenze possono essere implementate nella didattica sotto diversi aspetti:

- Proporre materiali utili ed interessanti così da poter coinvolgere lo studente nel loro completamento
- Assicurarsi che lo studente sia seguito nella realizzazione delle prove, così da completarle in un tempo utile
- Sostegno per quanto riguarda i corsi impegnativi
- Porre un interesse particolare sugli studenti che hanno numero di tentativi precedenti per esame più alto della media

Grazie per l'attenzione
